


سوال ۱) الف) در اصل مفهوم ما $loss$ ما این است که فاصله هر نقطه از خوشه مورد نظرش را پیدا کند و آن را با هم جمع بزند و حاصل مقدار $loss$ ما به هم جمع بزند تا تابع $loss$ به وجود آید پس بدین است که اگر ما سعی کنیم تابع هزینه را به ازای هر خوشه مینیمم کنیم آن ظاهر به طور کلی حاصل جمع آن نیز مینیمم می شود و تابع $loss$ مینیمم می شود.

ب) (الف) در اینجا بدین گونه است که برای $node$ مناسب با تعداد خوشه ها انتخاب می کنیم و آن را جایگزین قرار می دهیم (همین درست انتخاب کردن جای اولیه $node$ ها باعث ایجاد $local opt$ می شود). و در هر مرحله آن مرکز را با توجه به تابع $loss$ جایگزین می کنیم تا مینیمم $loss$ کسری داشته باشد و این را تا جایی ادامه می دهیم که دیگر مرکز جای نشود پس حلقه می شود.

شان ۱



ج) روش بدین گونه است که تابع $loss$ ما به ازای K های مختلف رسم می کنیم و به یک نمودار رسم مقدار K مورد نظر آن جایی است که در نمودار با کم کردن K مقدار زیادی از $loss$ کم نشود مقدار K همان مقدار است. یک روش دیگر استفاده از silhouette score است که میزان شباهت یک نقطه با $cluster$ آن که در آن است را با $cluster$ های دیگر می سنجد و مورد دوم استفاده از gap statistics است که کل تغییرات درون $cluster$ ها را برای مقایسه مختلف K با یک مجموعه داده بررسی می کند.

روش silhouette score: مقدار silhouette را برای تمامی داده های به ازای مقایسه مختلف K حساب می کند پس به ازای هر K مقدار میانگین این استیازها را می گیریم و به آن استیاز بیشینه شو K مورد نظر یافت می شود.

روش gap statistics: مقدار $w_k = \frac{1}{\sum_{j=1}^K \frac{1}{2|S_j|} \sum_{x, y \in S_j} ||x - y||^2}$ را برای هر داده داخل $cluster$ ها به ازای K های مختلف پیدا می کند و یک $dataset$ هم ساز با $dataset$ اصلی می کند و میزان اختلاف w_k ها را پیدا می کند که بدین گونه است: $gap(K) = E[loss(w_k^{random})] - loss(w_k^{data})$ و حال K طوری انتخاب می شود که این اختلاف ماکسیمم شود یا میزان بهبود زیادی شاهد شود.

د) به توان تابع $loss$ را بدین گونه تعریف کرد: $L' = L + \lambda K$ برای λ های مختلف $overfit$ شدن را کم می کند یا محدود کردن تعداد $cluster$ ها و ممکن است با محدودیت های دنیای واقعی بهتر حاصل شود. معایب: امکان $underfit$ شدن به علت کم کردن تعداد $cluster$ ها و نیاز به تنظیم پارامتر λ دارد.

سوال (2) خیر به دلایلی زیر:

- ① مرکز یید میانگین وزن از تمام نقاط خوشه است که در آن از نظر آماری نماینده نقاط است. حرکت نقاط به سمت مرکز تقسیم می کند که آنها در منطقه تعریف شده خوشه باقی می ماند.
- ② اگر همه نقاط را به میزان ثابت به مرکز نزدیک کنیم آنگاه دیگر مشخصه مرکز معنی است مبهم باشد.
- ③ چون الگوریتم curse به noise و نقاط دور افتاده مقاوم است در این حالت معنی است که این حالت رفع نموده و اگر برای نقاط دور افتاده بررسی کنیم میزان کاهش فاصله دیده بهتر عمل می کند.

سوال (3) الف) $U^T U = I \quad U U^T = \Sigma \quad \Sigma = \Sigma^T \quad V^T V = I \quad V V^T = \Sigma$
 $A = U \Sigma V^T \rightarrow A^T = V \Sigma^T U^T = V \Sigma U^T$

$$AA^T = (U \Sigma V^T)(V \Sigma^T U^T) = U \Sigma V^T V \Sigma^T U^T = U \Sigma \Sigma^T U^T = U \Sigma^2 U^T$$

$$A^T A = (V \Sigma^T U^T)(U \Sigma V^T) = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T = V \Sigma^2 V^T$$

مقادیر ویژه A و A^T یک هستند و مقادیر ویژه AA^T و $A^T A$ برابر هستند و توان 2، A و A^T هستند.

ب) در سمت چپ داریم:

$$A^T A = V \Sigma^2 V^T \xrightarrow{V^T} V^T A^T A V = V^T V \Sigma^2 V^T V = \Sigma^2$$

چون با توجه به این که $Q^T Q = I$ ، $\Lambda = \Sigma^T \Sigma \rightarrow Q^T A^T A Q = \Lambda = \Sigma^2$
 $A^T A = Q \Lambda Q^T$ را می توان به صورت $Q^T A^T A Q$ نوشت که Q یک ماتریس معکوس است.

سوال (4) الف) از آنجایی که امکان sampling به توان 2 هر ستون داریم پس ستون های با نرم فرو بنیوسه بیشتر امکان انتخاب بالایی دارند و میزان خطای بین A و $CC^T A$ برای این اساس است که چقدر ماتریس C فضای ستون ماتریس A را نمایه می دهد. از آنجایی که rank C خفیه کمتر از A است پس تنها اطلاعاتی که دست می دهیم 5 چون $\|A\|_F = 0.1 \times 50 = 5$ در دست داریم می توان گفت:

$$\|A - CC^T A\|_F \leq \epsilon \|A\|_F = 0.1 \times 50 = 5$$

ب) مانند قسمت قبل ستون های انتخاب می شوند که نرم فرو بنیوسه بیشتری دارند. میزان خطای AB به نرم های جلا کوز A و B که با δ اسکله شده است مرتبط است پس:

$$\|AB - CR\|_F \leq \sqrt{5} \|A\|_F \|B\|_F \delta \rightarrow \|AB - CR\|_F \leq 283$$

مسئله 5 الف / جدول بدین گونه می شود :

	h	g	f	e	d	c	b	a
A	0	1	0	0	1	0	1	1
B	0	0	0	0	1	1	1	0
C	1	1	1	0	1	0	0	0

$$D_{jaccard}(h, g) = 1 - \frac{|g \cap h|}{|g \cup h|} = 1 - \frac{1}{2} = \frac{1}{2}$$

برای مثال :

$$\begin{aligned} h &= (d, e) \rightarrow \text{sum} = 1 \\ g &= (a, b, c, d) \rightarrow \text{sum} = 2 \end{aligned}$$

میزان شباهت آنها بدین گونه است :

Jaccard Distance

h	0							
g	0.5	0						
f	1	1	0					
e	1	1	1	0				
d	0.5	0.5	0.5	1	0			
c	1	0.5	0.5	1	0.5	0		
b	0.5	0.5	1	1	0.5	0.5	0	
a	0.5	0.5	1	1	0.5	1	0.5	0

حالا باید ببینیم این عناصر در دو دسته شدن را merge کنیم بر مبنای Jaccard Distance آنها. برای مثال g و h را merge می کنیم و آن دو را یک عضو می بینیم و باقیه میایم می کنیم. به این cluster را باقیه Jaccard Distance می کنیم و به د و c را merge می کنیم به بدین گونه می شود {a, b, c, d, e, f, g, h} از حسابات بهیچگونه صرف نظر می کنیم چون مانند تحت این است.

به در این حالت نیز دوباره یکبار باقیه ها را با توجه به Jaccard Distance ، merge می کنیم که ط به (h و g) می پیوندیم cluster حاصل بدین گونه می شود :

$$\{h, g, b, d\}, \{f\}, \{e\}, \{c\}, \{a\}$$

ب / حالا میایم جدول را به این بدون در نظر گرفتن فیلتر روی داده ها انجام می دهیم .

	h, g, b	d, c, a	f	e
A	$\frac{2+3+5}{3} = 3.33$	$\frac{5+4}{2} = 4.5$	—	1
B	$\frac{1+3}{2} = 2$	$\frac{3+4}{2} = 3.5$	2	1
C	$\frac{3+5}{2} = 4$	$\frac{3+4+2}{3} = 2$	4	—

$$U_A = (3.33, 4.5, 0, 1) \rightarrow \|U_A\| = \sqrt{3.33^2 + 4.5^2 + 1^2} = 5.7$$

$$U_B = (2, 3.5, 2, 1) \rightarrow \|U_B\| = \sqrt{2^2 + 3.5^2 + 2^2 + 1^2} = 4.6$$

$$U_C = (4, 2, 4, 0) \rightarrow \|U_C\| = \sqrt{4^2 + 2^2 + 4^2} = 6$$

$$U_A \cdot U_B = 3.33 \times 2 + 4.5 \times 3.5 + 2 \times 0 + 1 \times 1 = 23.41$$

$$U_A \cdot U_C = 3.33 \times 4 + 4.5 \times 2 + 0 \times 4 + 1 \times 0 = 22.32$$

$$U_B \cdot U_C = 2 \times 4 + 3.5 \times 2 + 2 \times 4 + 1 \times 0 = 23$$

$$\text{sim}(U_A, U_B) = \frac{23.41}{5.7 \times 4.6} = 0.89$$

$$\text{sim}(U_B, U_C) = \frac{23}{4.6 \times 6} = 0.83$$

$$\text{sim}(U_A, U_C) = \frac{22.32}{5.7 \times 6} = 0.65$$

$$\text{similarity}(A, B) = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|}$$

ج